Word Embeddings

29.10.2020

Plan

- One-hot encoding (OHE)
- Bag of words (BOW)
- TF-IDF
- Word2vec
- Doc2vec


One-hot encoding (OHE)

id	color	
1	red	
2	blue	
3	green	
4	blue	



id	color_red	color_blue	color_green
1	1	0	0
2	0	1	0
3	0	0	1
4	0	1	9

Bag of words (BOW)




TF-IDF

$$ext{tf}(t,d) = rac{n_t}{\sum_k n_k}$$

$$\mathrm{idf}(t,D) = \log \frac{|D|}{|\{\,d_i \in D \mid t \in d_i\,\}|}$$

Word2vec is a combination of models used to represent distributed representations of words in a corpus.




$$P(w_o|w_c) = rac{e^{s(w_o,w_c)}}{\sum_{w_i \in V} e^{s(w_i,w_c)}}$$

 ω_o — вектор целевого слова

 ω_c — это некоторый вектор контекста, вычисленный (например, путем усреднения) из векторов окружающих нужное слово других слов.


 $s(\omega_o, \omega_c)$ — это функция, которая двум векторам сопоставляет одно число. Например, это может быть упоминавшееся выше косинусное расстояние.

- CBOW
- Skipgram




Example:

«The quick brown fox jumps over the lazy dog.»





Architecture.




Output.

Hidden Layer Weight Matrix Word Vector Lookup Table!





Doc2vec





Links

Word Embeddings
Word2vec
FastText